

Caso para la Evaluación del Parcial 1: Clasificación curricular automática de recursos educativos mediante una Red Neuronal Multicapa (MLP)

Asignatura	Deep Learning (DLY0100)
Situación evaluativa	Encargo con presentación/defensa
Archivo de datos	Dataset_Clasificacion_Curricular_100000_LIMPIO.csv
Tipo de problema	Clasificación supervisada multiclase de etiqueta única

1. Contexto del caso

Una empresa EdTech administra una plataforma que reúne recursos educativos digitales de Matemática. Actualmente, la clasificación curricular de estos recursos se realiza de forma manual. Debido al volumen de materiales, la organización requiere automatizar la asignación de una categoría curricular principal a cada recurso.

Para esta evaluación se entrega un dataset ya preparado y depurado. Cada registro contiene características numéricas que representan propiedades del recurso educativo. El trabajo se centra en la construcción, entrenamiento, comparación y evaluación de una Red Neuronal Multicapa (MLP), no en procesos de ETL.

2. Objetivo del encargo

A partir del dataset proporcionado, desarrollar en Google Colab un Notebook en Python que implemente una Red Neuronal Artificial Multicapa (MLP), utilizando TensorFlow/Keras o PyTorch, para predecir la categoría curricular principal de un recurso educativo.

El problema corresponde a una clasificación multiclase de etiqueta única: cada recurso pertenece a una sola categoría. No corresponde a clasificación multietiqueta.

3. Dataset proporcionado

El archivo Dataset_Clasificacion_Curricular_100000_LIMPIO.csv contiene 100,000 registros y 23 columnas: 22 variables predictoras numéricas y 1 variable objetivo denominada categoria_curricular. El dataset no contiene valores faltantes ni registros duplicados y todas las variables ya se encuentran en formato numérico.

Por lo tanto, no se solicita realizar limpieza de datos, integración de fuentes, transformación de textos, eliminación de duplicados, tratamiento de valores nulos ni codificación de variables categóricas. El preprocesamiento se limita a las acciones necesarias para entrenar correctamente la red neuronal.

Codificación de la variable objetivo:

Valor	Categoría	Descripción general
0	NÚMEROS Y OPERACIONES	Números, operaciones, fracciones o decimales.
1	ÁLGEBRA Y FUNCIONES	Variables, ecuaciones, patrones o funciones.
2	GEOMETRÍA Y MEDICIÓN	Figuras, medición, ángulos o coordenadas.
3	DATOS Y PROBABILIDAD	Tablas, gráficos, estadística o probabilidad.

4. Variables del dataset

Todas las variables de entrada son numéricas. Las variables de proporción e índices toman valores entre 0 y 1; las demás corresponden a cantidades, porcentajes o niveles. No es necesario crear nuevas variables.

Variable	Descripción
nivel_escolar	Nivel escolar codificado numéricamente (5 a 12).
duracion_estimada_min	Duración estimada de uso del recurso, en minutos.
numero_paginas	Extensión equivalente del recurso.
numero_items	Cantidad de ejercicios, preguntas o actividades.
porcentaje_visual	Porcentaje estimado de contenido visual.
densidad_simbolos	Presencia relativa de símbolos matemáticos.
prop_operaciones_aritmeticas	Proporción asociada a operaciones aritméticas.
prop_fracciones_decimales	Proporción asociada a fracciones y decimales.
prop_variables_algebraicas	Proporción asociada a variables algebraicas.

prop_ecuaciones	Proporción asociada a ecuaciones.
prop_patrones_funciones	Proporción asociada a patrones y funciones.
prop_figuras_geometricas	Proporción asociada a figuras geométricas.
prop_medicion_angulos	Proporción asociada a medición y ángulos.
prop_coordenadas	Proporción asociada a coordenadas y ubicación espacial.
prop_tablas_graficos	Proporción asociada a tablas y gráficos.
prop_estadistica_descriptiva	Proporción asociada a estadística descriptiva.
prop_probabilidad	Proporción asociada a probabilidad.
prop_contexto_problemas	Proporción de situaciones contextualizadas o problemas.
dificultad_estimada	Nivel estimado de dificultad del recurso (1 a 5).
ejemplos_resueltos	Cantidad de ejemplos resueltos.
elementos_visuales	Cantidad estimada de elementos visuales.
indice_interactividad	Índice numérico de interactividad del recurso (0 a 1).
categoria_curricular	Variable objetivo codificada con valores 0, 1, 2 o 3.

5. Desarrollo solicitado

- Carga y revisión del dataset:** Cargar el archivo en Google Colab, verificar sus dimensiones, tipos de datos y distribución de la variable objetivo. El dataset ya está limpio; no se solicita ETL.
- Preparación para el entrenamiento:** Separar las 22 variables predictoras (X) de la variable objetivo (y), dividir los datos en conjuntos de entrenamiento, validación y prueba, y aplicar escalamiento o normalización a las variables de entrada si se considera necesario. Justificar brevemente las decisiones realizadas.
- Definición de una MLP sencilla:** Implementar una red neuronal multicapa con 1 o 2 capas ocultas. No se requiere una arquitectura compleja. Justificar de manera breve la cantidad de capas y neuronas seleccionadas.
- Funciones de activación, pérdida y salida:** Utilizar una función de salida adecuada para cuatro clases y justificarla. Comparar únicamente dos funciones de activación en las capas ocultas, por ejemplo ReLU y Tanh. Además, realizar una comparación simple de funciones de error/pérdida. Para mantener la dificultad acotada, puede compararse Sparse Categorical Crossentropy con Mean Squared Error; en este último caso la variable objetivo puede transformarse temporalmente a formato one-hot.
- Configuración del entrenamiento:** Definir épocas, tasa de aprendizaje y tamaño de batch. Para facilitar el trabajo, se recomienda utilizar entre 20 y 50 épocas, learning rate entre 0,0005 y 0,001 y batch size de 32 o 64.
- Experimentos controlados:** Realizar experimentos simples modificando un parámetro a la vez y manteniendo los demás constantes. Como mínimo, comparar dos valores de batch size o dos valores de learning rate. Presentar una tabla y/o gráfico que permita interpretar el efecto observado.
- Regularización:** Aplicar Dropout como técnica de regularización y comparar el modelo sin Dropout y con Dropout. No se exige aplicar múltiples técnicas de regularización.
- Optimización:** Utilizar un optimizador apropiado para el entrenamiento de la MLP, por ejemplo Adam, e indicar brevemente por qué fue utilizado. No se exige comparar distintos optimizadores.
- Evaluación del modelo:** Calcular accuracy, precision, recall y F1-score. Para facilitar la comparación entre modelos, se recomienda informar precision, recall y F1-score en promedio weighted, además de accuracy. Presentar un cuadro resumen.
- Ajuste y modelo final:** A partir de los resultados obtenidos, realizar al menos un ajuste sencillo al modelo, por ejemplo neuronas, Dropout, batch size o learning rate, y justificar por qué la configuración final fue seleccionada.
- Conclusiones:** Explicar brevemente qué configuración obtuvo mejores resultados, qué efecto tuvo la regularización y qué limitaciones o mejoras podrían considerarse.

6. Experimentos mínimos requeridos

Para evitar una búsqueda excesiva de configuraciones, no se solicita realizar Grid Search, Random Search ni una exploración amplia de hiperparámetros. Se espera únicamente evidencia suficiente para comparar y justificar decisiones.

Experimento	Comparación mínima	Qué mantener fijo
1. Activación	ReLU vs Tanh	Arquitectura, pérdida, batch y learning rate
2. Error/pérdida	Sparse Categorical Crossentropy vs MSE	Arquitectura y parámetros de entrenamiento
3. Parámetro de entrenamiento	Batch 32 vs 64 o LR 0,001 vs 0,0005	Todos los demás parámetros
4. Regularización	Sin Dropout vs con Dropout	Arquitectura y parámetros restantes
5. Ajuste final	Modelo base vs modelo ajustado	Comparar con las mismas métricas

7. Requisitos de documentación

- El Notebook debe incluir código organizado, ejecutable y comentado.

- Cada decisión importante debe explicarse mediante celdas Markdown breves y claras.
- Los experimentos deben incluir tablas o gráficos comparativos.
- No se evalúa ETL ni ingeniería de datos; se evalúa la preparación necesaria para usar el dataset en una red neuronal.
- No se solicita procesamiento de texto, imágenes, CNN, RNN, Transformers, modelos multimodales ni clasificación multietiqueta.

8. Productos a entregar

- Cuaderno Jupyter desarrollado en Google Colab (.ipynb), utilizado como informe técnico.
- Código disponible según las indicaciones del docente.
- Presentación y defensa técnica basada en el Notebook, con una duración máxima de 10 minutos.

9. Aspectos a explicar en la defensa

Durante la presentación se espera que los estudiantes expliquen, de forma breve y utilizando evidencia del Notebook: cómo prepararon los datos, la arquitectura MLP utilizada, las funciones seleccionadas, los parámetros de entrenamiento, el efecto de Dropout, las métricas obtenidas y la razón por la cual seleccionaron el modelo final.

Importante: el dataset ya está depurado y listo para el modelamiento. La dificultad del encargo debe concentrarse en los fundamentos de Deep Learning evaluados en el Parcial 1.