

■ Clasificación Curricular Automática con MLP

*Evaluación Parcial N.º 1
Fundamentos de Deep Learning (DLY0100)*

Integrantes:

- Rahyza Novoa
- Nicolás Salas

Profesora:

Elizabeth Chicata Castro

Problema, objetivo y datos

Problema: clasificar material educativo de matemáticas en 4 categorías curriculares a partir de 22 variables numéricas.

Objetivo: implementar una MLP en Keras y justificar experimentalmente cada decisión.

100 mil

registros

22


variables

4

categorías

Preparación

- 0 nulos y 0 duplicados: no requiere ETL.
- Split 70/15/15 estratificado; test aislado hasta el final.
- StandardScaler ajustado solo con train.
- Semilla 42 reiniciada antes de cada entrenamiento.



Desbalance moderado (ratio 1,53): se usa F1 ponderado como métrica principal.


Arquitectura de la MLP



3.684 parámetros entrenables

Pérdida Sparse Categorical Cross-Entropy	Optimizador Adam lr = 0.0005	Batch size 256	Épocas Early Stopping patience = 10
---	---	---------------------------------	--

Funciones de activación, salida y pérdida



Gradiente medio por capa en una red de 5 capas, antes de entrenar

1.959×

Sigmoide

atenuación salida → primera capa

2,9×

ReLU

atenuación salida → primera capa

Activación: ReLU



- En la red 64-32 las 4 activaciones empatan: $\Delta F1 = 0,0024$.
- En la red profunda, sigmoide desvanece el gradiente y converge en 56 épocas; ReLU en 36.
- Adam compensa gradientes pequeños, por eso el F1 final es similar.

Salida y pérdida: Softmax + CE

- Softmax + CE: F1 0,9128; las salidas suman siempre 1,000.
- Sigmoide + MSE: F1 0,9132, pero sus salidas suman entre 0,82 y 1,49.
- Se elige por coherencia con 4 clases excluyentes, no por accuracy.


Épocas, learning rate y batch size

Parámetro	Valores probados	Elegido	Evidencia
Learning rate	0.1 · 0.01 · 0.001 · 0.0005	0.0005	Mayor F1 (0,9100) y menor val_loss (0,2394). Con 0.1 colapsa: accuracy 30,22% y val_loss ≈ ln 4.
Batch size	32 · 64 · 128 · 256	256	F1 0,9129 en 25 s, frente a 0,9100 en 150 s con batch 32.
Épocas	100 sin parada	Early Stopping	Mínimo de val_loss en la época 16; patience = 10 y restore_best_weights.



Un parámetro a la vez: el resto se mantiene fijo en cada experimento.

Efecto de la regularización




F1 (barras azules) frente a brecha train-val (barras naranjas)

Técnica	F1	val_loss mín.	Brecha
Ninguna	0,9133	0,2381	+0,0021
Dropout 0.2	0,9132	0,2341	-0,0013
Dropout 0.4	0,9138	0,2353	-0,0069
L2 0.001	0,9130	0,2459	+0,0023
BatchNorm	0,9120	0,2423	+0,0028
Dropout + BN	0,9131	0,2355	-0,0024

Hallazgo principal

Las 6 variantes quedan en un rango de F1 de solo 0,0019, porque el sobreajuste de base ya era leve. Se elige Dropout 0.2: su diferencia con Dropout 0.4 (0,0006) está bajo el umbral de 0,005, y tiene el menor val_loss (probabilidades mejor calibradas) y la menor brecha absoluta. Las brechas negativas se deben a que la accuracy de entrenamiento se mide con neuronas apagadas.

Comparación de configuraciones



Las 19 corridas del notebook principal; en naranja, la configuración seleccionada


LR y batch explican +0,0053 de los +0,0056 de mejora.

Etapas	F1	Δ F1
Baseline	0,9076	—
LR 0.0005	0,9100	+0,0024
Batch 256	0,9129	+0,0029
Early Stopping	0,9133	+0,0004
Dropout 0.2	0,9132	−0,0001

Otras comparaciones

- Optimizadores: Adam, RMSprop y SGD empatan (F1 ≈ 0,913). Se mantiene Adam.
- Arquitecturas: con 22× más parámetros, F1 +0,0009. Se mantiene 64-32.

Modelo final frente al baseline



+0,0056

F1 validación

0,9076 → 0,9132

-2,8%

val_loss mínima

0,2409 → 0,2341

-0,0013

Brecha train-val

desde +0,0126

≈ 5×

Más rápido

152 s → 31 s

Resultados en test

0,9108

Accuracy

0,9108

Precision (weighted)

0,9108

Recall (weighted)

0,9108

F1-score (weighted)

Categoría	Precision	Recall	F1	Soporte
Números	0,9094	0,9007	0,9050	4.533
Álgebra	0,9091	0,9150	0,9120	4.045
Geometría	0,9120	0,9078	0,9099	3.460
Datos y Prob.	0,9139	0,9240	0,9189	2.962

Validación 0,9132 → test 0,9108: diferencia de solo 0,0025. Las decisiones tomadas sobre validación no se sobreajustaron a ese conjunto.

Cálculo con la matriz real: Números



Precision = $VP / (VP + FP)$
= $4.083 / (4.083 + 407) = 0,9094$

Recall = $VP / (VP + FN)$
= $4.083 / (4.083 + 450) = 0,9007$

F1 = $2 \cdot P \cdot R / (P + R) = 0,9050$

El F1 ponderado calculado a mano coincide con sklearn: 0,9108.

Errores del modelo y cómo mejorar



185

Números → Álgebra

confusión principal

164

Álgebra → Números

148

Geometría → Números

Números participa en las tres confusiones principales: por eso tiene el menor recall (0,9007).

Umbral de confianza

- Con umbral $\geq 0,80$: precisión 96,7%, cubriendo el 82,1%.
- El resto pasa a revisión manual.

Conclusiones y posibles mejoras

Conclusiones

- MLP 64-32 con ReLU, Softmax y Cross-Entropy; Adam 0.0005, batch 256, Dropout 0.2 y Early Stopping. F1 en test: 0,9108.
- La mayor mejora proviene del learning rate y del batch size; la regularización mejora la calibración más que el F1.
- Las funciones y arquitecturas rinden de forma equivalente en esta red; las diferencias aparecen en el gradiente y en la velocidad de convergencia.
- El desempeño en test confirma la generalización: solo 0,0025 bajo validación.

Posibles mejoras

- Búsqueda conjunta de hiperparámetros (Keras Tuner), en lugar de variar uno a la vez.
- Validación cruzada estratificada para estimar la variabilidad de las métricas.
- Umbral de confianza con revisión manual para los registros de baja certeza.
- Nuevas variables para separar Números de Álgebra, y `class_weight` para subir el recall de Números.



■ Gracias

¿Preguntas?

Repositorio

github.com/Nicolas-Salas/deep-learning-ep1